Universidad Francisco Marroquín

Machine Learning for business

Christian Medina



Proyecto #1

Cynthia Santos - 20230493

José Antonio Valdés L. - 20230050

Predicción de la cancelación de clientes en una empresa de telecomunicaciones

Este proyecto fue realizado con la intención de ayudar a una empresa de telecomunicaciones a decidir a qué clientes debe contactar primero su equipo de retención durante el Q4. Se construyó un modelo que calcula el riesgo de cancelación de cada cliente y comprobamos si usarlo ahorraría más dinero que los métodos sencillos que la empresa podría aplicar.

Problema de negocio

La empresa atiende a 7,043 clientes de telefonía e internet en California. En el trimestre analizado (Q3) cancelaron 1,869 clientes (26.5 %). Pagaban en promedio $74 al mes, por lo que cada cliente perdido equivale a unos $890 al año. El motivo principal de cancelación es la competencia (841 clientes, cerca del 45 % de las bajas), seguido de la actitud del personal, la insatisfacción y el precio. El churn se concentra en los contratos mes a mes (46 %), frente a 11% en contratos de un año y 2.5 % en contratos de dos años.

Stakeholder. La Gerencia de Retención de Clientes (CRM). Cada trimestre debe decidir a qué clientes dirigir la campaña de retención (llamada, descuento, migración a contrato anual o mejora de servicio) con un presupuesto limitado: unos 2,000 clientes a 50 cada uno (100,000 en total).

Pregunta de negocio. ¿Qué clientes tienen mayor probabilidad de cancelar su servicio, para que el equipo de retención los contacte primero?

Objetivo analítico. Clasificación binaria sobre Churn Value (se va / se queda) usando el perfil del cliente, sus servicios, su contrato y su facturación. Se excluyeron las columnas que solo se conocen después de la cancelación o que son resultado de otro modelo (Customer Status, Churn Label, Churn Score, Churn Category, Churn Reason y Satisfaction Score), porque causarían fuga de datos.

Por ejemplo, Satisfaction Score por sí sola predecía el churn casi a la perfección (AUC 0.95): con puntaje 1–2 todos los clientes se iban y con 4–5 ninguno. El valor de vida del cliente se usó solo para estimar el impacto económico.

La métrica principal es el recall de la clase churn: de cada 100 clientes que realmente se van, cuántos detecta el modelo. Importa más que la precisión porque perder a un cliente cuesta

~$890 al año y una llamada innecesaria cuesta $50. Como apoyo usamos PR-AUC, ROC-AUC, precisión y F1. La meta fue recall ≥ 0.75 con precisión ≥ 0.50, superando dos líneas base: predecir que nadie se va y contactar a los clientes con contrato mes a mes.

Estimación de impacto. Se mide como ahorro neto anual de la campaña:

- ahorro neto = (clientes contactados que se iban × 30 % de éxito × $890) – (2,000 × $50)

Datos

Se usó el Telecommunications Industry Customer Churn Dataset (un Kaggle basado en una muestra de IBM) en la cual habían 7,043 clientes de una telefónica ficticia de California durante el trimestre Q3. Las cinco tablas (demografía, ubicación, población, servicios y estado) se unieron a través de Customer ID, y tras la limpieza quedaron 33 predictores. El 26.5% de los clientes se va, así que la exactitud engaña: predecir “nadie se va” acertaría el 73.5% de las veces. La exploración mostró que el churn es mayor en:

- Contratos mes a mes (46%)
- Los primeros seis meses de antigüedad (53%)
- La Offer E (53%)
- Fibra óptica (41%)
- Pago con cheque por correo (37%)

Los clientes con soporte técnico o seguridad en línea tienen cerca de la mitad de churn. Son asociaciones, no causas comprobadas.

No hubo duplicados ni valores imposibles. Los vacíos de Offer (55 %) significan "sin oferta" y los de Internet Type (21.7 %) corresponden exactamente a los clientes sin internet. Se rellenaron con categorías propias, sin usar promedios, para no inventar información.Los datos atípicos eran parte del comportamiento real, por lo que no se eliminó ninguno.

Los valores atípicos eran comportamiento real (por ejemplo, clientes con reembolsos o con hijos en variables donde la mayoría tiene cero), así que no se eliminó ninguno.

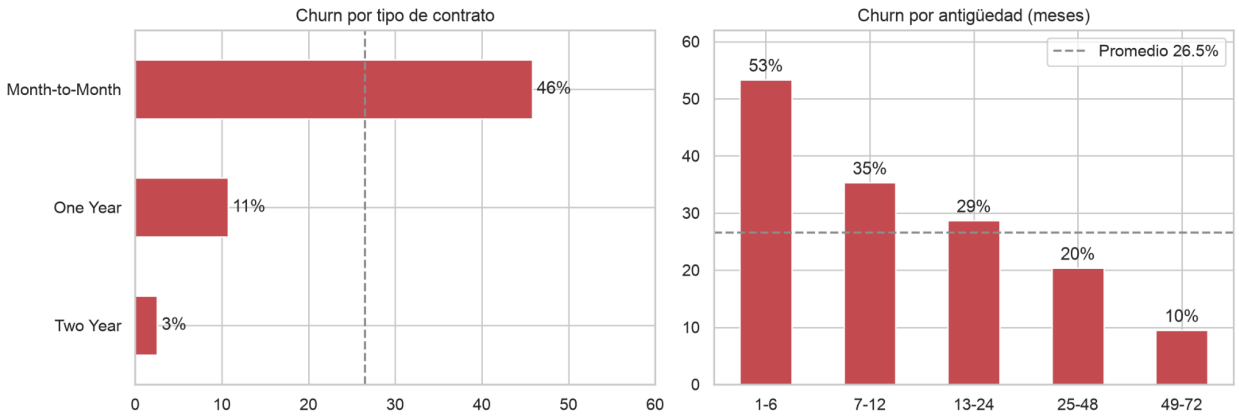


Figura 1. El churn se concentra en los contratos mes a mes y en los primeros meses de la relación con el cliente.

Metodologia

Se siguió CRISP-DM mediante pipelines reproducibles en Kedro. Se crearon tres variables (número de servicios, cliente nuevo y cargo mensual promedio histórico), se codificaron las categóricas y se escalaron las numéricas solo para la regresión logística. Los datos se dividieron 80/20 con estratificación y semilla fija. Se compararon tres modelos: regresión logística (simple y explicable), Random Forest (captura patrones no lineales) y Gradient Boosting (suele ser el más fuerte en datos tabulares). Los hiperparámetros se ajustaron con GridSearchCV, validación cruzada de 5 particiones y PR-AUC como criterio.

Selección del modelo y resultados

Modelo	Recall	Precisión	ROC-AUC	PR-AUC	Ahorro neto
Línea base: mayoritaria	0.000	0.000	0.500	0.265	—
Línea base: regla mes a mes	0.874	0.446	0.741	0.423	$138,224
Regresión logística	0.861	0.583	0.903	0.766	$267,021

Random Forest	0.799	0.624	0.899	0.754	$264,352
Gradient Boosting	0.850	0.612	0.914	0.800	$272,359

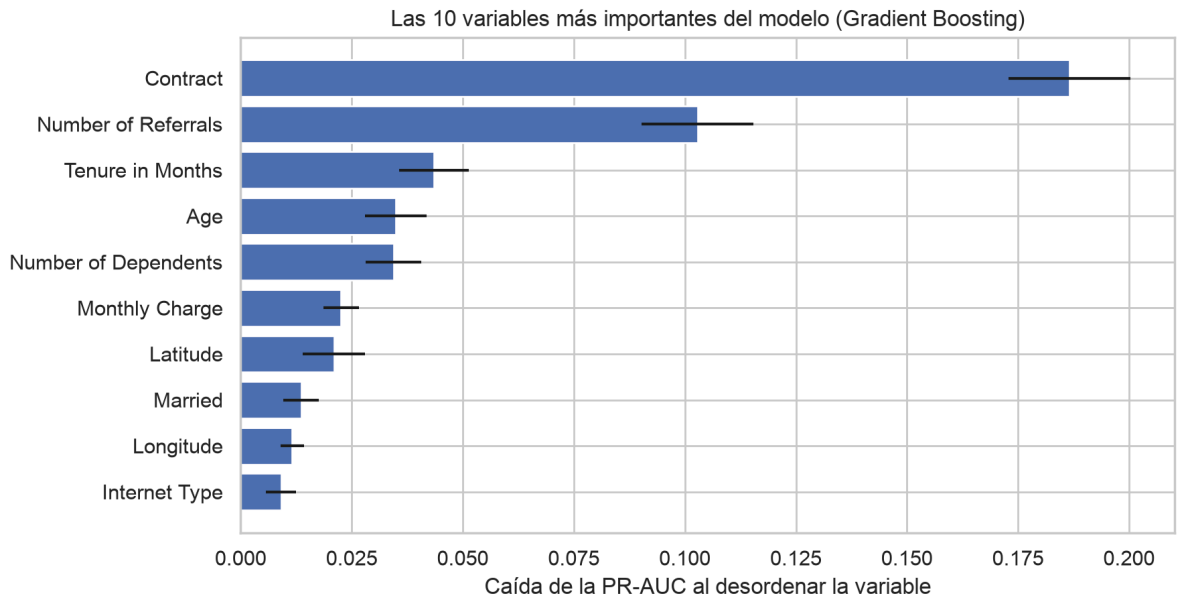
Se eligió Gradient Boosting (tasa de aprendizaje 0.05, profundidad 3, 200 iteraciones) dado a que ordena mejor a los clientes por riesgo, genera el mayor ahorro, es estable (PR-AUC de 0.798 en validación cruzada y 0.800 en prueba) y puede ser re-entrenado fácilmente. Su costo es una menor interpretabilidad que la regresión logística, que queda como segunda mejor opción dado a que está solamente a 2% del ahorro. Random Forest detecta menos clientes que se van, y la regla mes a mes solo logra su recall alto contactando a cerca de la mitad de los clientes.

Resultados

- **Simulamos una campaña que contacta a 2,000 clientes ($100,000)**

Estrategia	Clientes contactados que se iban	Clientes retenidos	Ahorro neto
Contactar al azar	531	159	$41,743
Regla: contrato mes a mes	892	268	$138,224
Regresión logística	1,375	412	$267,021
Random Forest	1,365	409	$264,352
Gradient Boosting	1,395	418	$272,359

Medimos la importancia de cada variable con *permutation importance*: desordenamos una variable a la vez y medimos cuánto empeora el modelo. Las más importantes son el tipo de contrato, el número de referidos, la antigüedad, la edad y el número de dependientes.



Interpretación de negocio

Un recall de 0.85 significa que el modelo señala a unos 85 de cada 100 clientes que realmente se van. Una ROC-AUC de 0.914 significa que, entre un cliente que se fue y uno que se quedó, asigna mayor riesgo al que se fue el 91% de las veces. Al contactar a los 2,000 clientes de mayor riesgo se alcanzan unos 1,395 de los 1,869 que se van (~75%), con un ahorro neto de $272,359 frente a $41,743 al contactar al azar (6.5 veces más) y $138,224 con la regla simple. Se retienen unos 259 clientes más que al azar, y cada dólar invertido devuelve $3.72 en ingreso retenido.El modelo confirma lo que mostró la exploración. El riesgo se concentra en clientes con contrato mes a mes, en sus primeros meses, sin referidos y sin dependientes.

Recomendaciones:

1. Ejecutar la campaña del Q4 con la lista ordenada del modelo, de mayor a menor riesgo, hasta agotar el presupuesto.
2. Ofrecer incentivos para migrar a contrato anual a los clientes mes a mes es la variable mas importante del modelo.
3. Crear un programa de acompañamiento durante los primeros seis meses.
4. Revisar la Offer E antes de volver a ofrecerla.
5. Investigar precio y calidad de la fibra óptica frente a la competencia.
6. Piloto de soporte técnico gratuito y pago automático con tarjeta, con grupo de control.

En producción, el flujo es actualizar los datos cada trimestre, ejecutar el pipeline, entregar el ranking a CRM y registrar quién aceptó. Se reentrena cada trimestre y se monitorean el recall, la precisión, la tasa real de retención y el ahorro neto por campaña.

Limitaciones

Los datos cubren un solo trimestre y una empresa ficticia, sin precios de la competencia, calidad de red ni llamadas a servicio al cliente. La tasa de retención de 30% y el ingreso de $890 son supuestos: la campaña llega al punto de equilibrio con cerca de 8% de éxito, pero con 15% el ahorro neto baja a unos 86,000. Unos 605 clientes contactados se habrían quedado de todos modos (~$30,000) y unos 474 que se van no son alcanzados. El modelo predice quién se irá, no quién responderá a una oferta, y edad y estado civil son variables de entrada que conviene revisar para evitar ofertas discriminatorias.

Conclusión

Cerca de uno de cada cuatro clientes se va, y el churn se concentra en contratos mes a mes, clientes nuevos y fibra óptica. Gradient Boosting cumple todas las metas y supera ambas líneas base, así que la empresa pasa de adivinar a priorizar. Recomendamos adoptarlo para ordenar a los clientes cada trimestre y combinarlo con incentivos a contratos anuales y acompañamiento de seis meses. Como próximos pasos, ajustar el umbral al presupuesto, medir la importancia de las variables, recolectar la satisfacción antes de la cancelación y correr un piloto controlado para medir la retención real.

Link al repositorio: https://github.com/Antonio-3108/Proyecto-ML-for-Buisness